1. Objetivo

Muchas aplicaciones modernas requieren el procesamiento de datos no estructurados, especialmente textos escritos en lenguaje natural. En este proyecto exploraremos el uso de *autoencoders* para representar fragmentos de texto (*chunks*) como vectores densos (*embeddings*), los cuales pueden utilizarse posteriormente en tareas complejas mediante técnicas estándar de aprendizaje automático. Utilizaremos estos embeddings como punto de partida para la clasificación de textos empleando métodos de aprendizaje supervisado.

2. Dataset

Trabajaremos con el conjunto de datos *The Movies Dataset* disponible en Kaggle.[1] Este conjunto contiene metadatos de aproximadamente 45.000 películas incluidas en el dataset completo de MovieLens. Incluye películas estrenadas hasta julio de 2017. Los datos abarcan información como el elenco, el equipo de producción, palabras clave del argumento, presupuesto, ingresos, carteles promocionales, fechas de estreno, idiomas, compañías productoras, países, número de votos y calificaciones promedio en TMDB.

A continuación, se presentan los aspectos más relevantes del conjunto de datos:

- **Número de observaciones:** 45.466
- **Número de variables:** 24
- `title`: Título oficial de la película.
- `overview`: Sinopsis o descripción breve del argumento principal.
- `genres`: Lista de géneros asociados a la película, representada en formato JSON.
- `cast`: Lista de actores que participaron en la película.
- `crew`: Información sobre el equipo de producción, como directores y guionistas.
- `plot_keywords`: Palabras clave relacionadas con la trama.
- `budget`: Presupuesto destinado a la producción.
- `revenue`: Ingresos generados por la película.
- `posters`: Enlaces a los afiches promocionales.
- `release_dates`: Fechas de estreno en distintos países.
- `languages`: Idiomas en los que se distribuyó la película.

[1] `https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset`

- `production_companies`: Compañías responsables de la producción.
- `countries`: Países donde se produjo o lanzó la película.
- `tmdb_vote_counts`: Número de votos en TMDB.
- `tmdb_vote_averages`: Promedio de calificaciones en TMDB.

3. Especificaciones

- El objetivo del proyecto es entrenar un modelo de clasificación que prediga el género (`genre`) a partir de la sinopsis (`overview`) de cada película.
- Utilizaremos embeddings generados a partir de la variable `overview` para construir el conjunto de características del modelo.
- El modelo de embeddings será `all-MiniLM-L6-v2`, provisto por la librería `Sentence-Transformers`.

4. Preprocesamiento

Para preparar el conjunto de datos, se deben aplicar los siguientes pasos de preprocesamiento:

1. **Filtrado de sinopsis vacías:** Eliminar películas sin descripción en la variable `overview`.
2. **Filtrado por cantidad de géneros:** Conservar únicamente películas que pertenezcan a un solo género, generando una nueva columna `genre`.
3. **Filtrado por géneros válidos:** Mantener solo películas pertenecientes a alguno de los siguientes 13 géneros con suficiente representación: Drama, Comedy, Documentary, Horror, Thriller, Western, Action, Animation, Science Fiction, Crime, Music, Adventure.
4. **Codificación del género:** Asignar a cada género un código numérico único en una nueva columna `genre_code`.
5. **Filtrado por fragmentación de sinopsis:** Eliminar películas cuya sinopsis se divida en varios fragmentos al ser procesadas. Conservar solo aquellas sinopsis que forman un único bloque de texto. Para esto puede usarse la clase `SentenceTransformersTokenTextSplitter`.
6. **Reducción de columnas:** Conservar únicamente las columnas relevantes: `title`, `overview`, `genre` y `genre_code`.

7. **Tamaño final del dataset:** El conjunto final debe contener 13.744 observaciones y 4 variables.
8. **Partición del conjunto de datos:** Dividir el dataset en conjuntos de entrenamiento y prueba, utilizando una proporción de 80 % para entrenamiento y 20 % para prueba. Esta separación permite evaluar el modelo en datos no vistos.

5. Resultados esperados

Se puede utilizar cualquier algoritmo supervisado de clasificación. El objetivo es alcanzar una exactitud (*Accuracy*) aproximada de 0,6 y una puntuación F1 cercana a 0,45. Los resultados deben evaluarse mediante validación cruzada para garantizar su robustez.

6. Calificación

El proyecto debe desarrollarse en **grupos de máximo tres estudiantes**. Su valor corresponde al 50 % de la nota total del curso. La calificación se divide de la siguiente manera:

1. **Notebook: 60 %**
   a) Código funcional que resuelva el problema planteado (3 pts).
   b) Código adecuadamente comentado (1 pt).
   c) Explicación en `markdown` que acompañe las celdas de código principales (1 pt).
2. **Reporte: 40 %**
   a) Presentación clara del problema (1.5 pts).
   b) Descripción de los métodos utilizados (1.5 pts).
   c) Análisis de resultados y discusión (2 pts).

7. Notebook

El notebook constituye el núcleo del proyecto y debe contener el código que implementa y resuelve el problema. Algunas pautas importantes:

- El notebook no debe replicar el contenido del reporte. Su función es presentar el código y explicarlo de manera clara y estructurada.
- Se recomienda incluir únicamente código de alto nivel. No se sugiere la creación de funciones o clases auxiliares innecesarias.
- Puede utilizar funciones provistas por librerías como `pandas`, `langchain`, `sklearn` y `sentence_transformers`.
- Cada celda de código debe estar precedida por una explicación en `markdown`, y el código debe contar con comentarios que faciliten su comprensión.

8. Reporte

El reporte debe demostrar una comprensión general del problema, sus componentes y la solución propuesta. Debe ser conciso, pero incluir los detalles técnicos esenciales. Debe contener al menos las siguientes secciones:

1. **Presentación del problema:** Descripción clara del problema que se quiere abordar y la solución propuesta.
2. **Métodos:** Breve descripción de los métodos usados para representar los datos y resolver el problema. El algoritmo principal de creación de embeddings debe ser explicado en detalle.
3. **Resultados y discusión:** Presentación y análisis de los resultados obtenidos. Se deben incluir métricas vistas en clase. Las figuras son preferibles a las tablas y deben ir acompañadas de leyendas claras. Si el problema no se resolvió exitosamente, se debe indicar qué falló y proponer posibles mejoras.

9. Pautas de estilo

Las siguientes pautas deben seguirse al elaborar el reporte:

- El reporte debe estar redactado en LaTeX.
- Tamaño de fuente: 11 pt.
- Formato de doble columna.
- Márgenes: 3 cm en todos los lados.
- Extensión máxima: tres (3) páginas.
- Los errores ortográficos, gramaticales o de estilo penalizarán la nota del reporte.